

# Generating Personalized Recipes from Historical User Preferences

**Bodhisattwa Prasad Majumder\*, Shuyang Li\*, Jianmo Ni, Julian McAuley**

Computer Science and Engineering

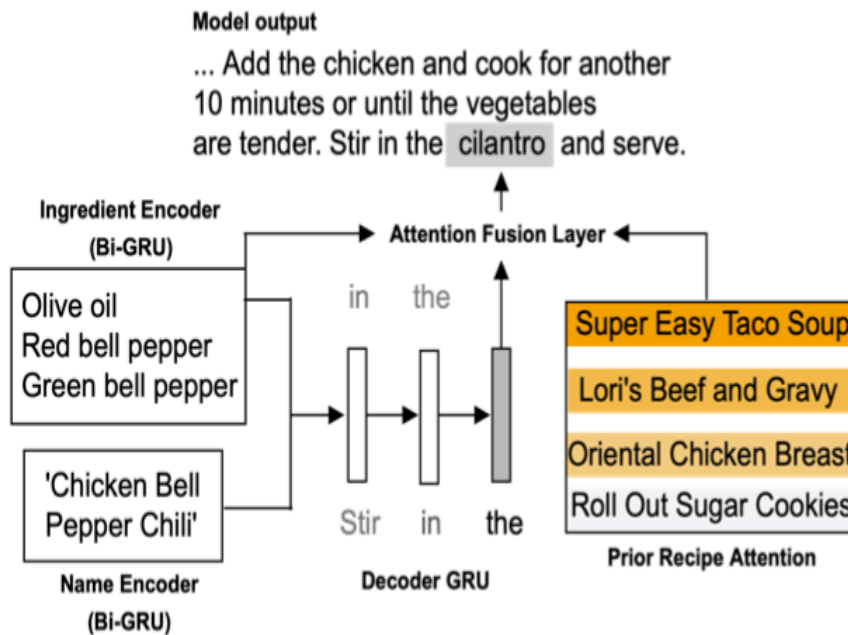
University of California, San Diego

{bmajumde, sh1008, jin018, jmcauley}@ucsd.edu

# 概要

- 料理の名前、不完全な材料などの詳細情報  
→ユーザーの好みに沿った完全に自然な言語で構成されるレシピ
- ユーザーが過去に利用したレシピのテクニックやレベルを fusion attention layerで合成しレシピのテキスト生成をコントロールする
- 180Kのレシピ、700Kのレビューを含む巨大なデータセット
- パーソナライズされていないベースラインのモデルと比較し、よりもっともらしくパーソナライズされたレシピを生成できることを示した。

# 提案手法



○Encoder : 3つに特微量を埋め込み

料理名: $\mathbf{n}$ , 材料: $\mathbf{i}$ , カロリー: $\mathbf{c}$ ,  $d_h$ : hidden size

$$\mathbf{n}(L_n) \rightarrow \mathbf{BiGRU} \rightarrow \mathbf{n}_{\text{enc},j} \in \mathbf{R}^{2d_h}$$

$$\mathbf{i}(L_i) \rightarrow \mathbf{BiGRU} \rightarrow \mathbf{i}_{\text{enc},j} \in \mathbf{R}^{2d_h}$$

$$\mathbf{a}_t^i = \sum_{j=1}^{L_i} \alpha(\mathbf{i}_{\text{enc},j}, \mathbf{h}_t) \times \mathbf{i}_{\text{enc},j}.$$

$$\mathbf{c} \rightarrow \mathbf{Projection Layer} \rightarrow \mathbf{c}_{\text{enc}} \in \mathbf{R}^{2d_h}$$

$$\alpha(K, Q) = \frac{\exp(\tanh(W_\alpha[K + Q] + \mathbf{b}_\alpha))}{Z}$$

○Decoder : 2層GRU

$$\mathbf{h}_0 (\in \mathbf{R}^{d_h}) = W_{h_0} [\mathbf{n}_{\text{enc},L_n}; \mathbf{i}_{\text{enc},L_i}; \mathbf{c}_{\text{enc}}] + \mathbf{b}_{h_0}$$

$$\mathbf{h}_t, \mathbf{o}_t = \mathbf{GRU}([w_{r,t}; \mathbf{a}_t^i], \mathbf{h}_{t-1}).$$

To bias generation toward user preference

# パーソナライゼーション

## ○Prior Recipe (Name) Attention

$R_u^{k+}$ : 過去k回に使用したレシピ

(一時的な好みの変化に対応)

$\mathbf{r} \in \mathbf{R}^{d_r}$ : 埋め込みされたレシピ (料理名)

$$\mathbf{a}_t^{r_u} = \sum_{\mathbf{r} \in R_u^{k+}} \alpha(\mathbf{r}, \mathbf{h}_t) \times \mathbf{r}.$$

(過去使用したレシピのAttention Context)

## ○Prior Technique Attention

preference vector  $\rho_u$

Technique  $\mathbf{x} \rightarrow \mathbf{x} \in \mathbf{R}^{d_x}$

$$\mathbf{a}_t^{x_u} = \sum_{\mathbf{x} \text{ seen in } R_u^+} (\alpha(\mathbf{x}, \mathbf{h}_t) + \rho_{u,x}) \times \mathbf{x},$$

(過去に使用したレシピのテクニックのAttention Context)

## ○Attention Fusion Layer

時間tで計算されたcontextを計算し **decoder GRU** の出力と合成

$$\mathbf{a}_t^f = \text{ReLU} \left( W_f \left[ w_{r,t}; \mathbf{o}_t; \mathbf{a}_t^i; (\mathbf{a}_t^{r_u} \text{ or } \mathbf{a}_t^{x_u}) \right] + \mathbf{b}_f \right)$$

これを用いて確率が計算される。

$$P(S_{r,t}) = \text{softmax} \left( W_P [\mathbf{a}_t^f] + \mathbf{b}_P \right)$$

→ユーザーの好みを考慮した条件で尤度関数を最大化

## ○Recipe Dataset: Food.com

Split	# Users	# Recipes	# Actions	Sparsity <sup>3</sup>
Train	25,076	160,901	698,901	99.983%
Dev	7,023	6,621	7,023	—
Test	12,455	11,695	12,455	—

Table 1: Statistics of Food.com interactions

# 結果 (decoder: $k = 3$ ; $[top - k \text{ sampling}]$ , $d_h = 256$ )

Model	BPE PPL	BLEU-1	BLEU-4	ROUGE-L	D-1 (%)	D-2 (%)	UMA	MRR	PP (%)
NN	–	20.279	0.465	16.871	0.931	9.394	0.100	0.293	–
Enc-Dec	9.611	28.391	<b>3.385</b>	<b>25.001</b>	0.220	1.928	0.100	0.293	–
Prior Tech	9.572	<b>28.864</b>	3.312	24.920	0.233	<b>2.158</b>	0.128	0.319	62.821
Prior Recipe	9.551	27.858	3.215	24.822	0.231	2.062	0.302	0.412	<b>66.026</b>
Prior Name	<b>9.516</b>	28.046	3.211	24.794	<b>0.233</b>	2.080	<b>0.505</b>	<b>0.628</b>	61.165

- Adam optimizer
- lr:0.001
- decay rate:0.9

Table 2: Metrics on generated recipes from test set. D-1/2 = Distinct-1/2, UMA = User Matching Accuracy, MRR = Mean Reciprocal Rank, PP = Pairwise preference over baseline (evaluated for 310 recipe pairs per model).

- **Name-based NN(Nearest-Neighbor)**
- **Encoder-Decoder model** を比較対象として導入  
→ 過去のユーザーの好みベースラインに比べどれだけ生成クオリティに活用されているかを調査
- Personalized Model outperformed baseline in **BPE PPL**
- Comparable performance in **BLEU-1/4 and ROUGE-L**
- More diverse(**D-1/2**) and acceptable recipes

## BLEU, ROUGE

- 生成クオリティの評価として最適な手法ではない
- **BLEU-4**で劣っているのはレシピがパーソナライズされた書き方になっているので語句のレベルから逸脱しているため
- **BLEU-1**で劣っているPrior Nameは unigram-diverse(**D-1**)で高いスコアを示している

# 評価

<b>Input</b>	<b>Name:</b> Pomberrytini; <b>Ingredients:</b> pomegranate-blueberry juice, cranberry juice, vodka ; <b>Calorie:</b> Low
<b>Gold</b>	Place everything except the orange slices in a cocktail shaker. Shake until well mixed and well chilled. Pour into martini glasses and float an orange slice in each glass.
<b>Enc-Dec</b>	Combine all ingredients. Cover and refrigerate. Serve with whipped topping.
<b>Prior Tech</b>	Combine all ingredients. Store in refrigerator. Serve over ice. Enjoy!
<b>Prior Recipe</b>	Pour the ice into a cocktail shaker. Pour in the vodka and vodka. Add a little water and shake to mix. Pour into the glass and garnish with a slice of orange slices. Enjoy!
<b>Prior Name</b>	Combine all ingredients except for the ice in a blender or food processor. Process to make a smooth paste and then add the remaining vodka and blend until smooth. Pour into a chilled glass and garnish with a little lemon and fresh mint.

Table 3: Sample generated recipe. Emphasis on personalization and explicit ingredient mentions via highlights.

Model	Recipe Level Coherence	Recipe Step Entailment
Enc-Dec	1.77	0.72
Prior Tech	1.78	0.73
Prior Recipe	1.80	0.76
Prior Name	<b>1.82</b>	<b>0.78</b>

Table 4: Coherence metrics on generated recipes from test set.

## 定性的評価

- Prior Name: レモンとミントを推奨
  - UMAとMRRが高いPrior Name はよりパーソナライズされたレシピを生成した
  - BERTによって事前学習を行なったスコアリングモデル
- レシピのテキストの一貫性を評価(coherence)
- 料理のステップの順序の整合性(entailment)

## Human Evaluation

- baselineとpersonalized recipeの310ペアの比較
- 63% : baseline < personalized recipe
- Personalized Model
- 生成されたレシピの意味的なもっともらしさが向上している

# まとめ

- 不完全なレシピの詳細情報とユーザーの過去の好みから、パーソナライズされたレシピを生成した
- 巨大なデータセット から、生成モデルがもっともらしくパーソナライズされた、一貫したレシピを生成することをHuman Evaluationにより示した
- 説明テキストの一貫性を評価するモデルを導入することに成功し、そのモデルによって主張が強化された
- 今後の展望は、レシピの構造化された表現の生成を行い、材料の特性を扱うことである

# 評価手法詳細

- ROUGE-L: 要約との一致する最大のシーケンスを評価

- $Recall = \frac{LSC(summary_{words}, reference_{words})}{reference_{words}}$

- $Precision = \frac{LSC(summary_{words}, reference_{words})}{summary_{words}}$

- BLEU-N

- $BLEU = BP_{BLEU} * \exp\left(\frac{1}{N} \sum_{n=1}^N \log p_n\right)$

- $BP_{BLEU} = \begin{cases} 1 & (c > r) \\ e^{1-\frac{r}{c}} & (c \leq r) \end{cases}$   $r$ : 正解単語数,  $c$ : 出力単語数

- $p_n = \frac{\text{正解した } N\text{-gram}}{\text{全 } N\text{-gram}}$